

Triagem Explicada de Incidentes de Rede com LLM Especializado e RAG Local

Experiencia Criativa: Projeto Transformador I - Bacharelado em Ciencia da Computacao - PUCPR

Igor Mamus dos Santos, Felipe Ribas Boaretto, Leonardo dos Santos Marques, Joao Vitor Manfrim

I. DESCRICAO DO PROJETO

A triagem de incidentes de seguranca em redes de computadores e uma atividade critica para a protecao de infraestruturas de TI [1]. Sistemas de deteccao de intrusao (IDS) geram grandes volumes de alertas diariamente e uma parcela significativa sao falsos positivos ou carecem de contexto suficiente para tomada de decisao rapida [1],[3].

A literatura recente demonstra avancos no uso de Large Language Models (LLMs) para ciberseguranca, incluindo analise de logs e classificacao de ameacas [7],[9]. Contudo, a maioria das solucoes depende de APIs proprietarias em nuvem, levantando preocupacoes de privacidade, custo e dependencia de fornecedores externos [8].

Este projeto constroi um sistema 100% local de triagem explicada de incidentes de rede, combinando: (i) LLM especializado em ciberseguranca; (ii) Retrieval-Augmented Generation (RAG) [6] com base de conhecimento curada; e (iii) pre-classificador de Machine Learning classico. O sistema opera sem enviar dados a servicos externos.

Pergunta de pesquisa: Um LLM especializado, operando localmente com RAG, pode produzir triagens de incidentes de rede com classificacoes e explicacoes corretas, contextualizadas e uteis para analistas?

Objetivos especificos:

- Implementar pipeline de pre-processamento para CIC-IDS2017 [3] e UNSW-NB15 [4] com 15 categorias unificadas.
- Construir base RAG local com 4.435 documentos indexados em ChromaDB [12] (MITRE ATT&CK, Sigma Rules e documentos canonicos de classes IDS).
- Integrar Foundation-Sec-8B [7] Q8_0 via Ollama [11] com prompts chain-of-thought e saida JSON estruturada.
- Implementar pre-classificador Random Forest binario com acuracia $\geq 99\%$ para filtragem de trafego benigno.
- Conduzir ablation study de 6 configuracoes para medir contribuicao isolada de cada componente.

II. MATERIAIS E METODOS

O CIC-IDS2017 [3] contem 2,83 milhoes de registros com 80 features cobrindo DDoS, DoS, Brute Force, Port Scan, Botnet, Web Attacks e Infiltration. O UNSW-NB15 [4] contem 2,54 milhoes de registros com 49 features e 9 tipos de ataque (Exploits, Fuzzers, Backdoor, Shellcode, Worms etc.). Juntos totalizam 5,37 milhoes de registros e 15 categorias unificadas, com 80-87% de trafego benigno.

A base RAG e composta por tres fontes: 691 tecnicas MITRE ATT&CK [2] (STIX 2.1), 3.728 regras Sigma [5] de deteccao, e 16 documentos canonicos desenvolvidos neste projeto descrevendo caracteristicas de fluxo de rede para cada classe IDS. Este ultimo componente e o diferencial mais impactante, pois MITRE e Sigma descrevem comportamento em logs de sistema, nao em features de rede.

O Foundation-Sec-8B [7] (Llama 3 fine-tuned em ciberseguranca, quantizacao Q8_0, ~8,5 GB) e inferido via Ollama [11] usando /api/chat com JSON Schema estruturado para saida garantida. Embeddings: all-MiniLM-L6-v2 [10] (384 dims). Re-ranking: cross-encoder ms-marco-MiniLM-L-6-v2 [14] (top-20 -> top-5). Pre-classificador Random Forest [13] binario treinado com 200.000 registros por dataset.

Stack: Python 3.13, pandas 2.x, ChromaDB 0.4+, sentence-transformers 5.x, scikit-learn, Ollama 0.12.3. Hardware: RTX 5060 8 GB (22/33 camadas do modelo na GPU), 64 GB RAM. Latencia: ~22s/registro.

Tabela I - Resumo de Materiais e Metodos

Categoria	Descricao	Papel no Projeto
Datasets	CIC-IDS2017 [3], UNSW-NB.	Registros rotulados (5..
Bases RAG	MITRE ATT&CK [2], Sigma [.	Contexto para triagem
Modelo LLM	Foundation-Sec-8B Q8_0 [7]	Geracao de triagens
Embeddings	all-MiniLM-L6-v2 [10]	Vetorizacao RAG
Re-ranking	ms-marco-MiniLM-L-6-v2 [14]	Cross-encoder top20->t.
Pre-classif.	Random Forest [13] binario	Filtro Benign ($\geq 99\%$.
Inferencia	Ollama 0.12.3 [11], ChromaD.	Servidor LLM + vector.
Dev Stack	Python 3.13, pandas 2.x, scikit-	Pre-processamento e M.
Hardware	RTX 5060 8GB, 64GB RAM	Inferencia local (~22s/r.

III. ARQUITETURA E IMPLEMENTACAO

O sistema e dividido em tres etapas encadeadas:

Etapa 1 - Pre-processamento:

Carregamento de 8 CSVs CIC e 4 arquivos UNSW; remocao de colunas identificadoras (IPs, timestamps - prevencao de data leakage); substituicao de infinitos e NaN por mediana; clip de valores negativos; mapeamento de rotulos para 15 categorias unificadas; remocao de 8 colunas constantes e 25+ com correlacao >0,95; normalizacao MinMax no dataset unificado (parquets individuais preservam valores brutos para uso na triagem LLM).

Etapa 2 - Base RAG:

4.435 documentos indexados em ChromaDB com similaridade coseno. Recuperacao em dois estagios: busca densa (top-20 candidatos) seguida de re-ranking com cross-encoder (top-5 finais). Filtro de qualidade: contexto descartado se distancia densa >0,55 (calibrado empiricamente). Overhead do cross-encoder: ~2s/query.

Etapa 3 - Triagem com LLM:

(a) text_converter v2: features brutas convertidas em descricao textual com categorias discriminativas: FLOOD/ALTA/MODERADA/BAIXA para taxa de pacotes; UNIDIRECIONAL/SIMETRICO/EXFILTRACAO para forma do fluxo; assinaturas heurísticas automáticas para padrões conhecidos. Sanity check para micro-fluxos evita classificacao incorreta como FLOOD (Bug #21 corrigido).

(b) Prompts v2 com chain-of-thought: protocolo de raciocinio em 5 passos + 8 exemplos canonicos (DDoS, Reconnaissance, Benign, Brute Force, DoS, Exploits, Fuzzers, Backdoor). Saida JSON com attack_type (enum 15 categorias), severity, confidence, mitre_techniques, explanation e recommendations. JSON Schema forçado via grammar sampling no Ollama.

(c) Random Forest pre-filtro: treinado separadamente para CIC (99,8% acc) e UNSW (99,1% acc). Benigns com confianca >=95% saltam o LLM completamente, eliminando o problema de TN=0 do modelo LLM isolado e reduzindo latencia media.

IV. METODOLOGIA DE AVALIACAO

O experimento principal e um ablation study com 6 configuracoes executadas com o mesmo seed de amostragem. A unica variavel entre configuracoes e a combinacao de componentes ativos. Seeds fixos garantem conjunto de registros identico para comparacao justa.

Amostragem estratificada: N registros por classe (N=3 nos benchmarks), garantindo representacao de todas as 15 categorias mesmo com 80-87% de registros benignos. Pre-amostra de N*50 por dataset evita carregar 5 milhoes de linhas em memoria.

Metricas adotadas:

- Acuracia Exata: attack_type predito = ground truth (com dicionario de aliases para variantes de nomenclatura).
- Acuracia Binaria (metrica primaria): deteccao correta de Ameaca vs. Benigno - operacionalmente mais relevante.
- Precisao: TP/(TP+FP) - dos alertados como ameaca, quantos eram reais.
- Recall: TP/(TP+FN) - das ameacas reais, quantas foram detectadas.
- Matriz de confusao: TP, TN, FP, FN - FN = ameaca nao detectada = critico.

As 6 configuracoes avaliadas:

- 1_baseline_norag: LLM puro, sem RAG, sem RF (baseline).
- 2_norag_rf: LLM + Random Forest, sem RAG.
- 3_rag_only: LLM + RAG denso, sem rerank nem RF.
- 4_rag_rerank: LLM + RAG + cross-encoder rerank, sem RF.
- 5_rag_rerank_rf: LLM + RAG + rerank + RF (configuracao recomendada).
- 6_rag_rerank_rf_2stage: Config 5 + Stage 1 LLM binario (opt-in experimental).

Seeds utilizados: 834338 (Benchmark 1, antes do fix Bug #21) e 279880 (Benchmark 2, pos todos os fixes). Outputs em outputs/benchmarks/bench_<timestamp>/summary.json.

V. RESULTADOS EXPERIMENTAIS

Tabela II - Benchmark 1 (seed 834338, N=3/classe, 10 registros)

Configuracao	Exata	Binaria	Precis.	Recall	Tp/reg
1_baseline_norag	10,0%	90,0%	90,0%	100%	25,1s
2_rag_only	10,0%	90,0%	90,0%	100%	24,6s
3_rag_rerank	20,0%	90,0%	90,0%	100%	26,1s
4_rag_rerank_2stage	10,0%	60,0%	85,7%	66,7%	22,2s
5_rag_rerank_rf *	30,0%	100,0%	100%	100%	23,2s
6_full_stack	20,0%	70,0%	100%	66,7%	19,2s

* Melhor resultado. Bug #21 (Slood UNSW) ainda ativo neste benchmark. Config 5: TP=9 TN=1 FP=0 FN=0. Config 4 e 6: Stage 1 LLM prejudicou recall.

Tabela III - Benchmark 2 (seed 279880, N=3/classe, 7 reg - pos fixes)

Configuracao	Exata	Binaria	Precis.	Recall	Tp/reg
1_baseline_norag	0,0%	85,7%	85,7%	100%	32,1s
2_norag_rf	14,3%	100,0%	100%	100%	23,8s
3_rag_only	14,3%	85,7%	85,7%	100%	27,1s
4_rag_rerank	28,6%	85,7%	85,7%	100%	29,6s
5_rag_rerank_rf *	42,9%	100,0%	100%	100%	24,9s
6_rf_2stage	14,3%	28,6%	100%	16,7%	7,5s

* Melhor resultado do projeto: 42,9% exata, 100% binaria. Config 6 catastrofica: Stage 1 LLM classificou 5/6 ameacas como Benign (FN=5).

V.A - Predicoes por Registro (Benchmark 2, seed 279880)

Tabela IV - Predicao por registro (v=acerto, x=erro, [RF]=RF skip LLM)

Ground Truth	1_base	2_rf	3_rag	4_rank	5_rf*
Benign	x Shell	Ben[RF]	x BF	x Recon	Ben[RF]
DDoS	x Recon	x Recon	x Recon	x Recon	x Recon
DoS	x Recon	x Recon	x Recon	v DoS	v DoS
Exploits	x Shell	x Shell	x Recon	x Recon	x Recon
Fuzzers	x Recon	x Recon	x Recon	x Recon	x Recon
Generic	x Recon	x Recon	x Recon	x Recon	x Recon
Reconnaissance	x Shell	x Shell	v Recon	v Recon	v Recon

DDoS->Recon e limite intrinseco do dado: fluxos CIC individuais de DDoS e Reconnaissance sao morfologicamente identicos. Config 6 omitida (Stage 1 LLM: FN=5, binaria 28,6%).

V.B - Evolucao Temporal da Melhor Config

Tabela V - Evolucao temporal: melhor config por periodo

Periodo	Config	Exata	Binaria	TN
Mai/03 v1	RAG simples	20,0%	90,0%	0
Mai/03 v2	rag_rerank_rf	30,0%	100%	1
Mai/04 v2+fixes	rag_rerank_rf	42,9%	100%	1

Ganho total: +22,9pp exata, +10pp binaria, TN 0->1. Principal contribuicao: Random Forest (TN) + fix Bug #21 + prompts v2 (exata).

VI. ANALISE ABLATIVA

Tabela VI - Ablation Study: contribuicao marginal de cada componente

Componente adicionado	D Exata	D Binaria	Observacao
RAG denso (vs baseline)	+0 a +14p.	0pp	Instavel sem rerank
+ Cross-encoder rerank	+14pp	0pp	Ganho consistente
+ Random Forest	+14pp	+14pp	Unico que melhora.
Stage 1 LLM (opt-in)	-14 a -28p.	-57 a -71pp	NOCIVO - desativa.

Baseado em 2 benchmarks (seeds 834338 e 279880). Stack otima: RAG + cross-encoder + Random Forest. Stage 1 LLM desativado em producao.

Tabela VII - Random Forest: metricas de classificacao binaria

Dataset	Acuracia	F1	Cobertura Benign (conf>=9.
CIC-IDS2017	99,80%	99,49%	97,9% (risco 0,04% de FN)
UNSW-NB15	99,12%	96,61%	98,6% (risco 0,04% de FN)

Treinado separadamente para CIC e UNSW. Risco: 4 ameacas em 10.000 podem ser incorretamente filtradas como Benign.

VII. DISCUSSAO E LIMITACOES

Por que a acuracia exata tem teto intrinseco:

Um unico fluxo CIC de DDoS tem: ~3 pacotes, ACK flag, payload zero, 5 segundos. Um fluxo de DoS: ~2 pacotes, ACK, zero bytes, 3 segundos. Um fluxo de Reconnaissance: 1 pacote, SYN, zero bytes, 2 segundos. Nenhum modelo pode distinguir esses tres apenas com features de fluxo individual. Os rotulos foram atribuidos pelos pesquisadores do CIC observando padroes agregados de milhares de fluxos simultaneos. Esta e uma limitacao do dado, nao do modelo.

Limitacoes documentadas:

- L1: Amostras pequenas (7-10 reg/run) sem significancia estatistica. Mitigacao: estratificacao + multiplos seeds.
- L2: LLM isolado nunca prevê Benign (TN=0). Solucionado pelo Random Forest.
- L3: RAG com distancias altas para UNSW (protocolos numericos abstratos). Filtro 0,55 mitiga contexto irrelevante.
- L4: Stage 1 LLM binario nao confiavel com Foundation-Sec-8B - recall cai ate 16,7%. Descartado em producao.
- L5: Latencia ~22s/registro - impraticavel em producao sem GPU maior. Com A100 80GB: estimados <2s.
- L6: Reproducibilidade parcial - temperatura 0,2 nao e totalmente deterministica. Seeds fixos na amostragem, nao nas respostas do LLM.

Pontos fortes para defesa:

- Stack 100% local sem dependencia de APIs externas.
- 5,37M registros de dois datasets publicos amplamente usados na literatura.
- Ablation study rigoroso: 6 configs, seeds fixos, metrica por componente.
- 22 bugs documentados com causa raiz, fix aplicado e licao aprendida.
- 100% acuracia binaria (FN=0, FP=0) na melhor configuracao.
- Teto de acuracia exata fundamentado tecnicamente e defensavel.

VIII. PROXIMAS ETAPAS (8 SEMANAS RESTANTES)

Semanas 1-2 - Bateria de avaliacao completa:

- run_benchmark.ps1 -SeedsPerConfig 3 -Sizes 3,5,8 (~5h, 36 runs).
- Separacao CIC-only e UNSW-only para analise por dataset.
- Dados com significancia estatistica para o manuscrito.

Semanas 3-5 - Manuscrito final:

- Capitulo de Introducao, Revisao da Literatura e Metodologia.
- Resultados com tabelas, matrizes de confusao e ablation study.
- Discussao: limitacoes intrinssecas vs. de implementacao.

Semanas 6-7 - Avaliacao qualitativa:

- Selecao de 20-30 explicacoes geradas para avaliacao por especialistas.
- Criterios: coerencia tecnica, relevancia MITRE, acionabilidade.

Semana 8 - Revisao final:

- Interface Streamlit (opcional, se tempo permitir).
- Organizacao final do repositorio, testes adicionais, entrega.

REFERENCIAS

- [1] S. Bhatt, P. K. Manadhata, L. Zomlot, "The operational role of SIEM systems," IEEE Security & Privacy, vol. 12, no. 5, pp. 35-41, 2014.
- [2] MITRE Corporation, "MITRE ATT&CK Framework," 2024. <https://attack.mitre.org/>
- [3] I. Sharafaldin, A. H. Lashkari, A. A. Ghorbani, "Toward generating a new intrusion detection dataset," in Proc. ICISSP, 2018, pp. 108-116.
- [4] N. Moustafa, J. Slay, "UNSW-NB15: A comprehensive dataset for NIDS," in Proc. MilCIS, 2015, pp. 1-6.
- [5] T. Florek, S. Piekarski, "SigmaHQ Rules for SIEM systems," 2024. github.com/SigmaHQ/sigma
- [6] P. Lewis et al., "Retrieval-Augmented Generation for NLP tasks," NeurIPS, vol. 33, 2020, pp. 9459-9474.
- [7] Cisco, "Foundation-Sec-8B: A cybersecurity LLM," 2024. github.com/cisco-open/foundation-sec-8b
- [8] N. Moustafa et al., "Network intrusion detection using deep learning," IEEE Access, vol. 7, 2019.
- [9] A. Vaswani et al., "Attention is all you need," NeurIPS, 2017, pp. 5998-6008.
- [10] N. Reimers, I. Gurevych, "Sentence-BERT: Sentence embeddings using Siamese BERT-networks," EMNLP, 2019.
- [11] Ollama, "Run large language models locally," 2024. <https://ollama.com/>
- [12] ChromaDB, "Chroma: The open-source embedding database," 2024. trychroma.com
- [13] L. Breiman, "Random forests," Machine Learning, vol. 45, pp. 5-32, 2001.
- [14] R. Nogueira, K. Cho, "Passage re-ranking with BERT," arXiv:1901.04085, 2019.

Tabela VIII - Cronograma atualizado

Atividade	Sem1-	Sem3-	Sem6-	S8
Etapa 1: Pre-processamento datasets	DONE	-	-	-
Etapa 2: Base RAG + ChromaDB + rerank	DONE	-	-	-
Etapa 3: LLM + RF + prompts v2	DONE	-	-	-
Bateria benchmark (múltiplos seeds)	Em an.	-	-	-
Manuscrito TCC	-	X	-	-
Avaliacao qualitativa explicacoes	-	-	X	-
Interface Streamlit (opcional)	-	-	X	X
Revisao final e entrega	-	-	-	X

DONE = etapa concluida e funcional. Etapas 1-3 completas e testadas.